LSTM 기반 차량 주행궤적 예측 분석 과정 및 실험 결과 보고서

교통·물류 데이터과학 및 인공지능 PBL 과제 ①

5 조 정채환 · 전재현 · 진하영 · 최형빈

연구 목적과 문제 설정

과거 차량 궤적으로 미래 x·y 위치를 예측하는 기본 LSTM 모형을 구성한다. LSTM 유닛 수와 과거 관측·미래 예측 길이에 따른 성능 차이를 MAE·RMSE 로 비교한다.

연구 질문 1 같은 시간 조건에서 유닛 수를 64 개에서 128 개로 늘리면 오차가 줄어드는가?

연구 질문 2 같은 유닛·미래 길이에서 과거 관측을 1 초에서 2 초로 늘리면 오차가 줄어드는가?

연구 질문 3 같은 유닛·과거 길이에서 미래 예측을 3 초에서 5 초로 늘리면 원래 좌표 오차가 커지는가?

연구 요약

전처리된 US-101 전체 10,000 개 시나리오로 유닛 64·128 개 × 과거 1·2 초 × 미래 3·5 초의 8 개 모형을 비교했다. 같은 시간 조건에서 128 유닛의 정규화 오차가 낮았고, 과거 길이 증가의 이점은 일정하지 않았다. 미래 5 초의 원래 좌표 오차는 대응되는 3 초 조건보다 컸다.

추가 분석에서 검증으로 선택한 LSTM 의 구간 전체 Ego RMSE 는 일정속도 기준보다 3 초·5 초에서 각각 약 24.72%·29.26% 낮았다. 다만 차량·프레임 중첩과 단일 학습의 한계가 있어 결과를 현재 고정 분할 내 비교로 제한한다.

표 1 분석 범위와 지표 구분

구분	분석 대상	스케일과 평가 방식
과제 기본 결과	전체 7 대 차량의 x·y	정규화 좌표 성분 MAE·RMSE, 부재 차량 채움값 포함
해석용 기본 결과	전체 7 대 차량의 x·y	정규화를 역변환한 원래 좌표 성분 MAE·RMSE
추가 분석	평가 집합 Ego 차량	원래 좌표 성분 오차, 시간·상황·기준 모델·잔차 진단

과제 ②의 원본 NGSIM·CitySim 처리와 Convolutional Social Pooling LSTM 은 별도 수행 범위이다. 기본·추가 분석은 최신 저장 노트북 출력을 사용하며, 차량 단위 부트스트랩은 사용자가 제공한 별도 실행 화면의 결과를 반영했다. 기본 8 개 조건의 평가와 보조 분석을 구분한다.

1. 데이터 구성과 품질 점검

입력 파일은 US101_0750_0805_scene(sample).pickle 이다. Pickle 은 저장 형식이며 내부는 float64 NumPy 배열이다. 원본 raw_data 를 보존하고 모델용 좌표와 분석용 요약값을 별도 구성하였다.

표 2 배열 구조

축	크기	의미
시나리오	10,000	차량과 주변 차량의 연속 관측 구간
차량 슬롯	7	슬롯 0 은 Ego, 나머지는 주변 차량
시점	71	0.1 초 간격, 처음부터 끝까지 7 초
특성	14	ID·좌표·차량 크기·차종·운동 상태·차로·차두간격

표 3 원본 특성 정의

인덱스	특성	의미와 사용
0 / 1	Vehicle_ID / Frame_ID	차량·프레임 식별, 규모 및 중첩 점검
2 / 3	x / y	횡방향·종방향 좌표, 모델 입력과 정답
4 / 5	length / width	차량 길이·폭
6	class	차종 코드
7 / 8	speed / acceleration	속도·가속도, EDA 와 상황 분류
9	Lane_ID	차로 식별, 유지·변화 분류
10 / 11	Front_id / Rear_id	앞·뒤 차량 식별자
12 / 13	Headway / Time_headway	공간·시간 차두간격

고유 Ego 차량은 1,616 대다. 같은 차량이 여러 시나리오에 포함되므로 차량 수와 시나리오 수를 구분한다. 14 개 특성 각각의 NaN 은 669,033 개이고 무한대는 없었다. 모델용 전체 좌표 NaN 은 1,338,066 개, Ego 좌표 NaN 은 0 개였다. 주변 차량 부재를 나타내는 패턴과 실습 코드를 바탕으로 모델 배열에서만 NaN 을 0 으로 변환했다.

첫 시나리오에서 유효 슬롯의 차량 ID 유지와 프레임 간격 1 을 확인했다. 이 확인을 전체 시나리오의 시간 연속성 검증으로 확대 해석하지 않는다. 좌표·차량 크기는 NGSIM 원본과의 일부 대조에서 m 변환과 일관됐지만 전체 생성 코드의 단위 검증은 아니다. 따라서 추가 결과는 원래 좌표 스케일로 표시하고 속도·가속도는 저장값 기준으로 해석한다.

2. 탐색적 데이터 분석

2.1 단변량 분포와 상황 구성

Ego 차량의 시나리오별 초기 속도, 평균 속도, 평균 가속도를 요약했다. 전체 71 개 시점의 Lane_ID 가 한 번이라도 달라지면 변화로 분류했다. 차로 ID 유지 9,493 개(94.93%), 변화 507 개(5.07%)로 유지 상황이 다수였다. 이는 고유 차로 변경 사건 수가 아니다.

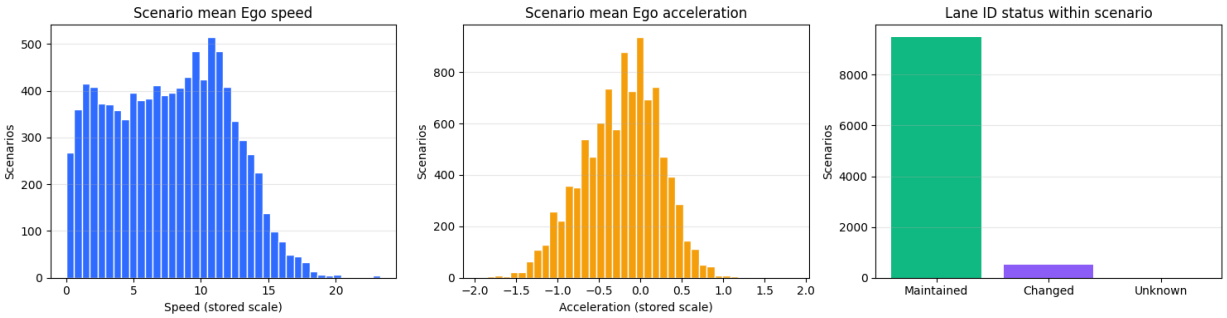


그림 1 시나리오별 평균 속도·평균 가속도 분포와 차로 ID 상태

표 4 주행 특성 요약

통계량	초기 속도	평균 속도	평균 가속도
평균	9.0135	7.6901	-0.2278
표준편차	4.0885	4.3460	0.4666
중앙값	9.2787	7.8225	-0.1986
최솟값	0.0000	0.0000	-1.9514
최댓값	21.7505	23.3108	1.8455

2.2 이변량과 다변량 관계

10,000 개 시나리오가 모두 관계 분석에 포함됐다. 차로 변화 집단의 평균 속도 중앙값은 11.9206 으로 유지 집단 7.5105 보다 높았다. 평균 가속도 중앙값은 각각 0.0840 과 −0.2131 이었다. 산점도에서 두 집단의 중첩도 커 속도·가속도만으로 상황을 명확히 구분하거나 인과관계를 주장하지 않는다.

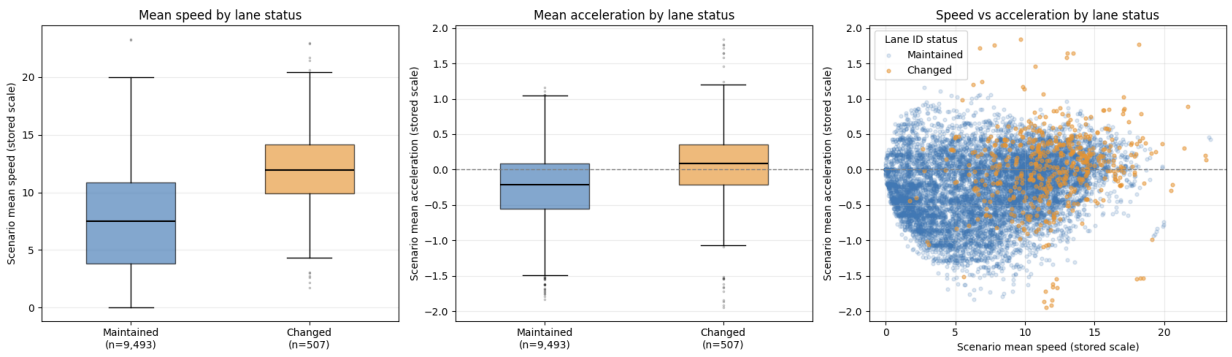


그림 2 차로 상태별 속도·가속도 박스플롯과 색상으로 구분한 산점도

2.3 대표 사례의 시간 변화

각 조건을 만족하는 첫 시나리오를 선택해 속도·가속도·차로 ID 의 시간 변화를 확인했다. 유지 사례는 원본 시나리오 0, 변화 사례는 3, 미래 속도가 모두 0 인 사례는 1 이다. 기준 시점 0 초 전후를 구분했고 서로 다른 시나리오를 연속 시계열로 이어 붙이지 않았다. 이 사례는 발생 빈도나 전형성을 대표하지 않는다.

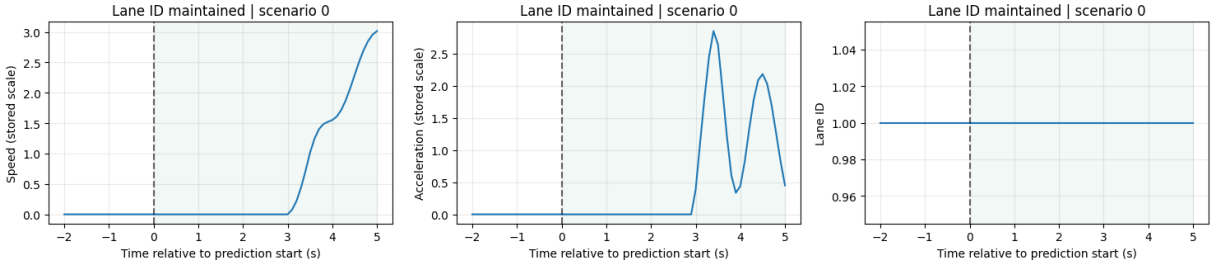


그림 3 대표 유지·변화·미래 정지 사례의 속도·가속도·차로 ID 시계열 (1/3)

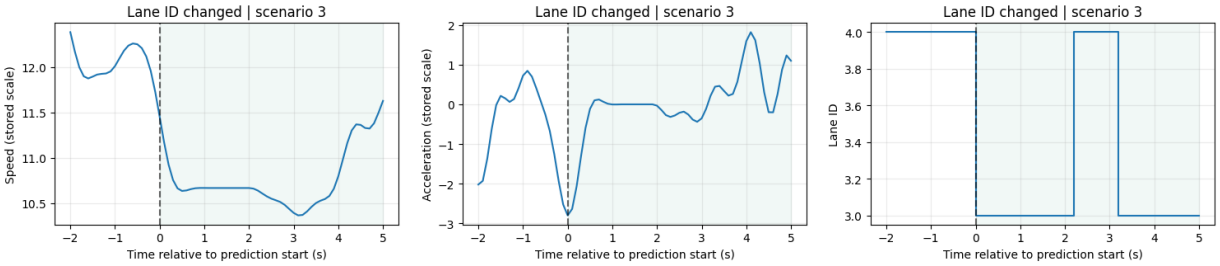


그림 3 대표 유지·변화·미래 정지 사례의 속도·가속도·차로 ID 시계열 (2/3)

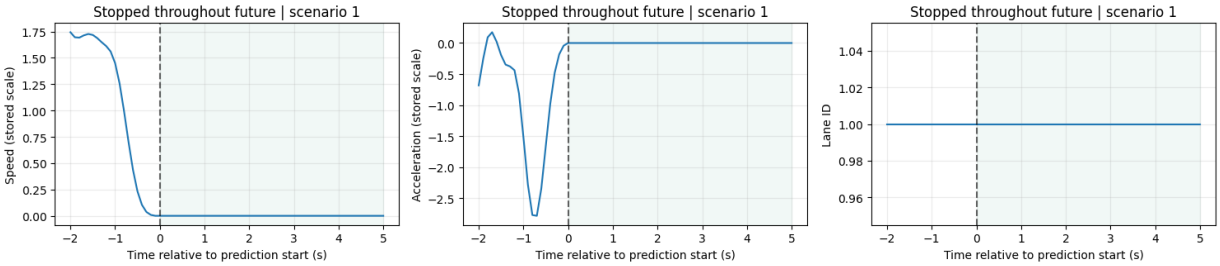


그림 3 대표 유지·변화·미래 정지 사례의 속도·가속도·차로 ID 시계열 (3/3)

3. 모델 입력과 실험 설계

3.1 좌표 변환과 시간 구간

모델은 7 대의 x·y 좌표를 시점당 14 개 값으로 사용한다. 모든 조건에서 관측 마지막 시점을 인덱스 20 으로 고정하고 이때 Ego 위치를 빼 상대좌표로 변환했다. 과거 1 초는 인덱스 10~20 의 11 개 관측점, 2 초는 0~20 의 21 개다. 미래 정답은 다음 시점부터 30 개 또는 50 개다. 71 개 관측점의 전체 길이에 맞춘 조건이며 공지의 시간 값은 예시다.

표 5 필수 8 개 실험 조건

실험	유닛	과거 초	미래 초	입력 시점	정답 시점
1	64	1	3	11	30
2	64	1	5	11	50
3	64	2	3	21	30
4	64	2	5	21	50
5	128	1	3	11	30
6	128	1	5	11	50
7	128	2	3	21	30
8	128	2	5	21	50

3.2 분할과 정규화

전체 자료를 학습 6,800 개(68%), 검증 1,200 개(12%), 평가 2,000 개(20%)로 분할했다. 난수 42 로 80% 개발 자료를 선택하고 그중 15%를 검증에 사용했다. 정규화 기준은 학습 자료에서만 계산했다. 모델 선택과 조기 종료에는 검증 손실을 사용했고, 평가 결과를 보고 조건을 다시 조정하지 않았다. 분할 중첩은 9 장에서 별도 확인한다.

3.3 모델 구조와 공통 학습 조건

모델 구조는 실습자료를 따라 LSTM → Dense → Reshape → Batch Normalization → ReLU → Dropout(0.01) → TimeDistributed Dense 로 구성했다. 마지막 출력은 선형으로 두어 음의 상대좌표도 예측한다. 아키텍처의 변경 유형은 LSTM 은닉 유닛 수 한 가지다.

표 6 모델 구조 예시와 공통 조건

항목	설정
예시 입력과 출력	과거 2 초: (21, 14) → 미래 5 초: (50, 14)
예시 파라미터 수	64 유닛: 전체 65,990 / 학습 65,962 / 비학습 28
최적화·손실	Adam, 학습률 0.001, 정규화 좌표 MSE
학습 조건	배치 64, 최대 100 epoch, 조기 종료 patience 10
모델 보존	검증 손실 최저 가중치 저장 및 복원
실행 환경	TensorFlow 2.21.0, Colab Tesla T4

기본 MAE 는 전체 좌표 성분의 절대오차 평균, RMSE 는 제곱오차 평균의 제곱근이다. 부재 차량의 채움값도 포함한다. 원래 좌표 지표는 정규화를 역변환해 계산했다. 이 지표는 유클리드 거리 오차인 ADE·FDE 와 다르다.

4. 필수 8 개 모델의 학습과 평가

4.1 학습 곡선

학습·검증 손실은 초반에 감소하고 후반에 완만해졌다. 최저 검증 손실 epoch 는 실험 순서대로 96, 98, 87, 62, 69, 51, 93, 71 이었다. 일부 모델은 최대 100 회에 가까이까지 개선돼 완전 수렴을 단정할 수 없다. Dropout 과 Batch Normalization 의 동작 차이 때문에 검증 손실이 학습 손실보다 낮은 구간을 곧바로 이상으로 판단하지 않는다.

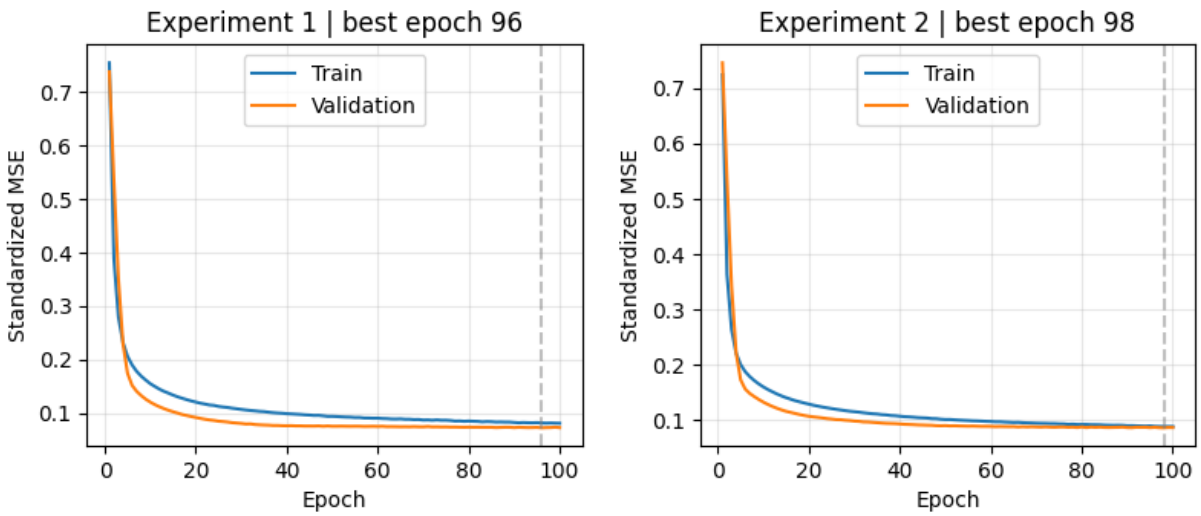


그림 4 실험 1~4 학습·검증 손실 확대 배치 (1/2)

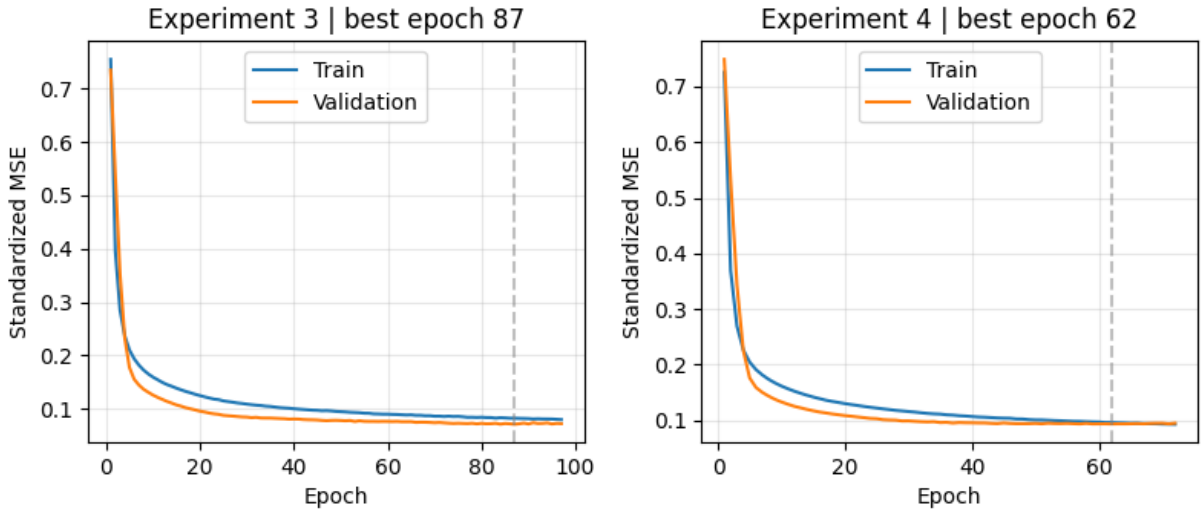


그림 4 실험 1~4 학습·검증 손실 확대 배치 (2/2)

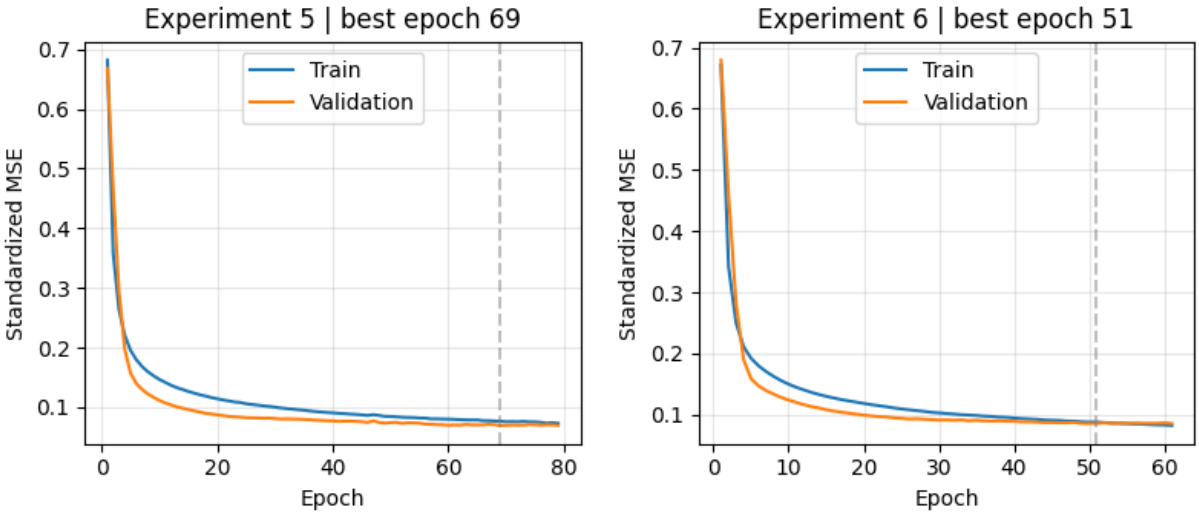


그림 5 실험 5~8 학습·검증 손실 확대 배치 (1/2)

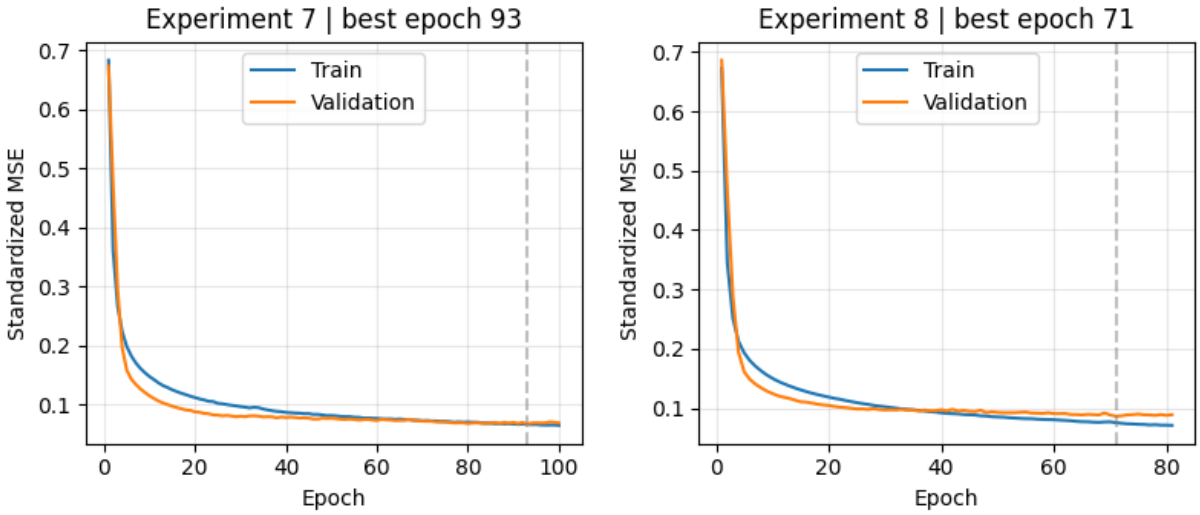


그림 5 실험 5~8 학습·검증 손실 확대 배치 (2/2)

4.2 MAE 와 RMSE 비교

표 7 정규화 좌표 기본 평가 결과

실험	유닛	과거 초	미래 초	검증 RMSE	평가 MAE	평가 RMSE
1	64	1	3	0.2703	0.1585	0.2655
2	64	1	5	0.2941	0.1839	0.3001
3	64	2	3	0.2666	0.1593	0.2663
4	64	2	5	0.3057	0.1889	0.3021
5	128	1	3	0.2634	0.1547	0.2612
6	128	1	5	0.2924	0.1813	0.2923
7	128	2	3	0.2588	0.1544	0.2608
8	128	2	5	0.2937	0.1842	0.2963

표 8 전체 7 대의 원래 좌표 평가 결과

실험	MAE	RMSE
1	1.1529	2.2363
2	1.7778	3.5309
3	1.1439	2.2666
4	1.8503	3.6323
5	1.0845	2.1162
6	1.7177	3.3699
7	1.0944	2.1379
8	1.7704	3.4658

검증 정규화 RMSE 로 예측 길이별 선택한 모델은 미래 3 초 실험 7(128 유닛·과거 2 초), 미래 5 초 실험 6(128 유닛·과거 1 초)이다. 평가 정규화 RMSE 도 각각 0.2608 과 0.2923 으로 해당 예측 길이 안에서 최소였다. 같은 시간 조건의 128 유닛은 64 유닛보다 정규화 RMSE 가 약 1.6~2.6% 낮았지만 반복 학습으로 안정성을 확인하지는 않았다.

과거를 1 초에서 2 초로 늘리는 효과는 일정하지 않았다. 원래 좌표 RMSE 는 대응되는 모든 조건에서 5 초 예측이 3 초보다 높았다. 예측 길이마다 정규화 기준이 달라 정규화 점수의 차이를 거리 증가량처럼 해석하지 않는다. 3 초 원래 좌표 RMSE 는 실험 5 가 가장 낮고 정규화 RMSE 는 실험 7 이 가장 낮아, 좌표별 스케일 가중에 따라 순위가 달라질 수 있다.

4.3 실제 궤적과 예측 궤적

검증으로 선택한 두 모델을 평가 집합 첫 시나리오인 원본 인덱스 1 에 적용했다. 미래 속도값과 종방향 실제 이동이 0 인 사례에서 모델은 전진을 예측했다. 그림은 Ego 만 표시하지만 모델 출력은 7 대 전체다. 한 사례의 실패를 전체 상황의 성능으로 일반화하지 않는다.

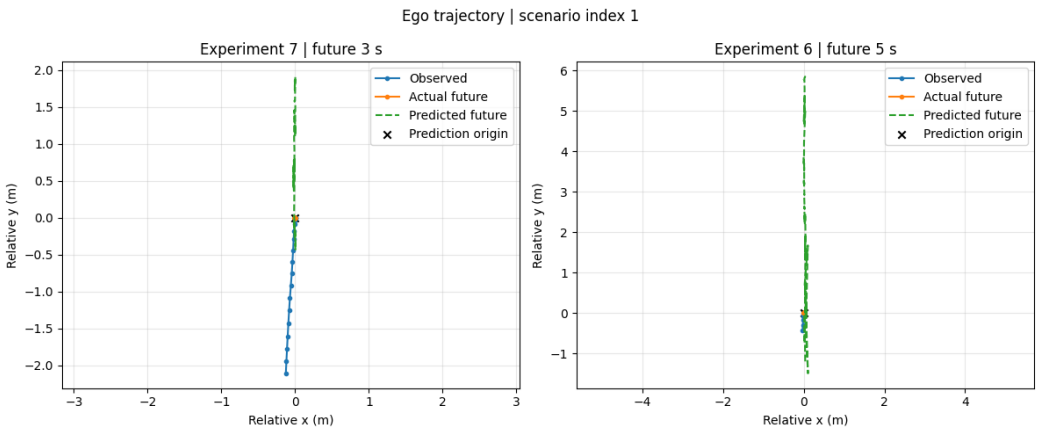


그림 6 같은 평가 사례의 실제·예측 궤적 비교 왼쪽 3 초 오른쪽 5 초

주변 차량을 포함한 궤적 비교를 위해 평가 집합에서 71 개 시점에 완전 관측된 차량 슬롯 수가 가장 많은 첫 사례인 시나리오 11 을 추가했다. 선택은 예측 오차와 무관하며, 미래 관측 여부를 이용한 사후 설명용 사례다. 실험 7 과 6 의 같은 장면에서 차량 7 대의 실제·예측 궤적을 비교한다.

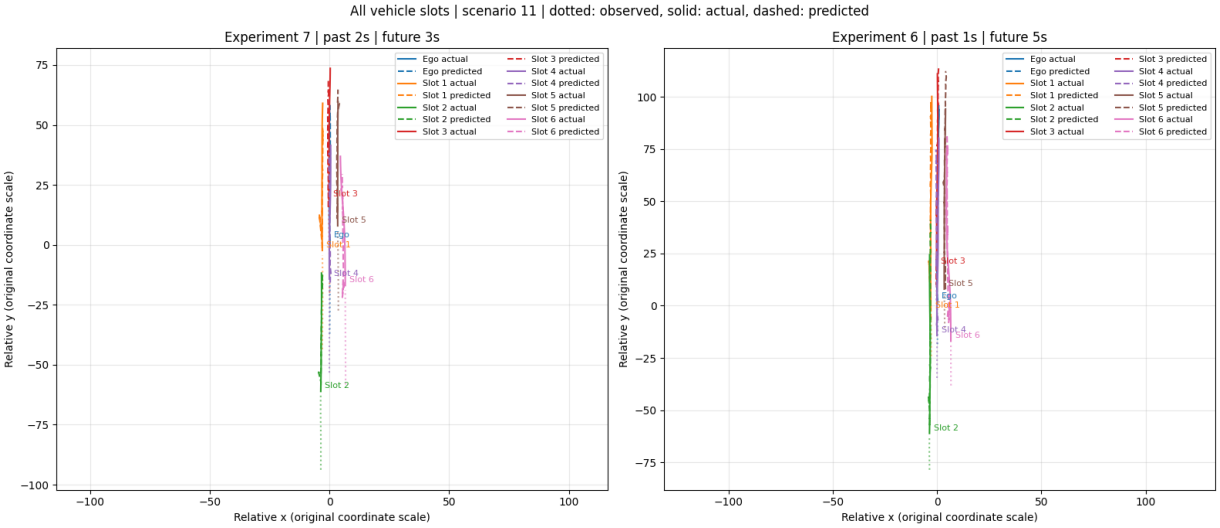


그림 6-1 시나리오 11 의 7 대 차량 실제·예측 궤적 왼쪽 3 초 오른쪽 5 초

차량별 색을 구분했으며 점선은 관측 과거, 실선은 실제 미래, 파선은 예측 미래다. 부재 차량의 채움값과 정답이 없는 시점은 표시하지 않는다. 원본 그림은 x·y 축의 단위 길이를 같게 유지하므로 종방향 이동에 비해 작은 횡방향 차이는 압축되어 보인다. 이 사례만으로 전체 정확도를 판단하지 않는다.

5. 예측 시간과 차로 상태별 오차

저장 모델을 동일 평가 집합에 다시 적용한 전체 정규화 MAE·RMSE 는 기존 값과 표시된 여섯째 소수점 자리까지 일치했다. 추가 분석은 결측이 없는 Ego 의 원래 좌표 성분 오차를 사용한다. 원래 좌표 지표와 정규화 기본 표를 혼합하지 않는다.

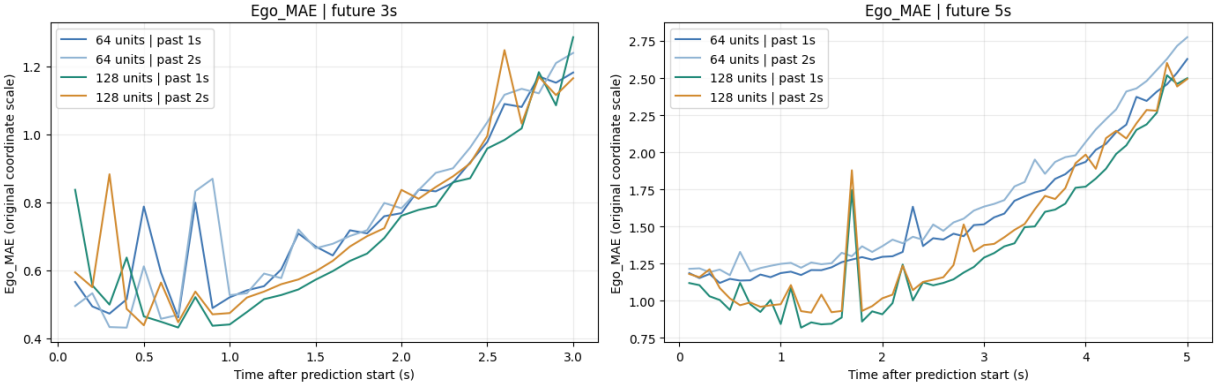


그림 7 8 개 모델의 미래 시점별 Ego MAE·RMSE (1/2)

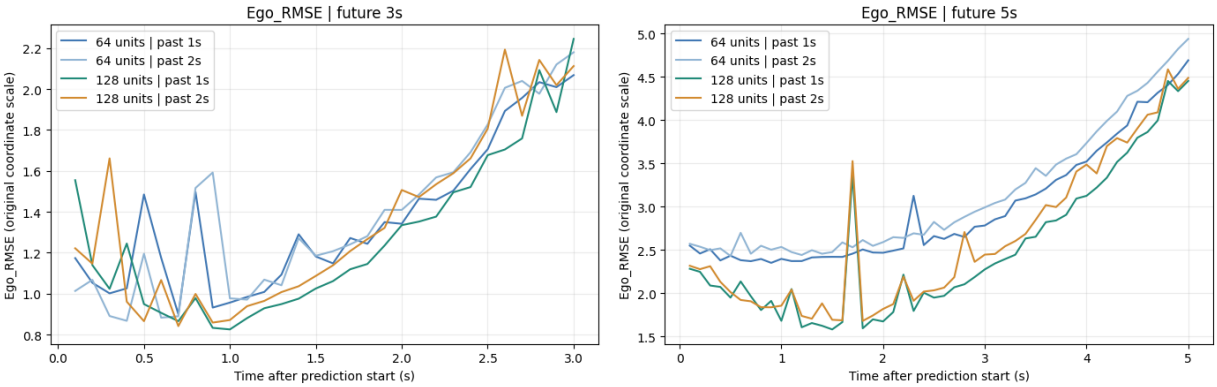


그림 7 8 개 모델의 미래 시점별 Ego MAE·RMSE (2/2)

오차는 예측 초반에 감소한 뒤 후반으로 갈수록 증가하는 경향이었다. 모든 시점에서 단조 증가하지는 않으며 중간의 뾰족한 변화도 존재한다. 해당 변화의 원인은 확정하지 않았다. 구간 평균만으로 시간별 성능 차이를 충분히 설명할 수 없다.

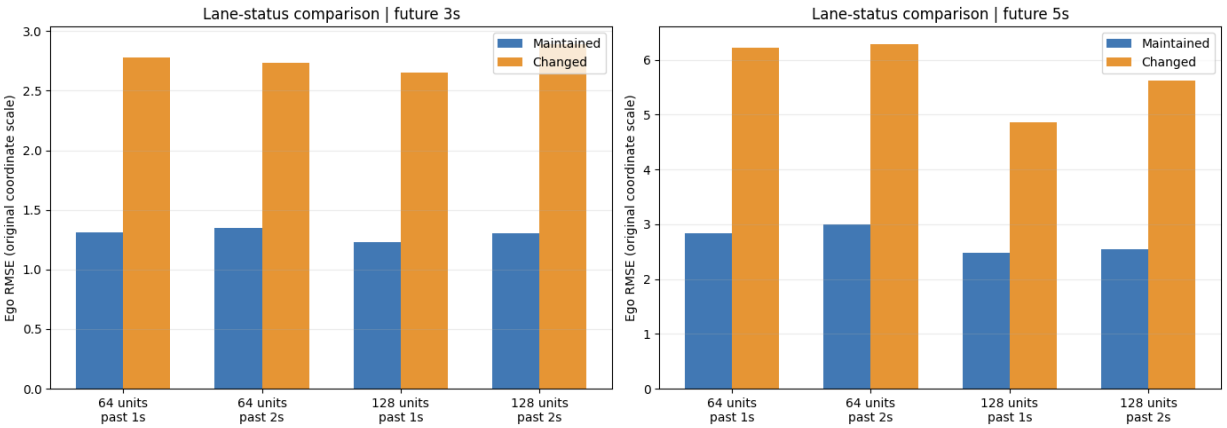


그림 8 전체 7 초 기준 차로 ID 유지·변화별 Ego RMSE

표 9 차로 상태별 Ego RMSE

실험	미래 초	유지 n	유지 RMSE	변화 n	변화 RMSE
1	3	1914	1.3093	86	2.7824
2	5	1914	2.8300	86	6.2172
3	3	1914	1.3506	86	2.7379
4	5	1914	2.9964	86	6.2906
5	3	1914	1.2330	86	2.6526
6	5	1914	2.4804	86	4.8595
7	3	1914	1.3030	86	2.8926
8	5	1914	2.5506	86	5.6194

평가 집합의 유지 사례는 1,914 개, 변화 사례는 86 개였다. 모든 모델에서 변화 집단 RMSE 가 높았다. 두 집단은 속도·가속도 분포도 다르고 같은 차량이 반복 포함될 수 있어 차로 변화의 인과 효과로 해석하지 않는다. 분류는 전체 7 초 기준이므로 변화가 미래 예측 구간에 발생했다고 단정하지 않는다.

6. 정지와 감속 상황의 예측 실패

추가 분석으로 평균 점수뿐 아니라 특정 상황의 오차 방향과 큰 실패 사례를 점검했다. 정지는 미래 속도값이 모두 0 인 경우, 감속은 정지가 아니면서 기준 시점 대비 미래 마지막 속도가 낮고 미래 평균 가속도가 음수인 경우다. 이외 유효 사례는 기타로 분류했다. 실제 미래를 사용하는 사후 그룹이며 실시간 상황 탐지기가 아니다. 예측 길이에 따라 그룹 구성도 달라진다.

표 10 상황별 Ego 오차와 종방향 편향

실험	상황	n	평균 MAE	MAE P90	끝점 y 편향	y 과대예측 %
7	정지	28	0.6074	1.0773	1.7370	92.8571
7	감속	1261	0.6966	1.2452	0.8495	65.4243
7	기타	711	0.7992	1.3927	-0.8723	37.2714
6	정지	16	1.2545	1.7150	4.4850	100.0000
6	감속	1104	1.3509	2.4497	3.4882	77.1739
6	기타	880	1.3990	2.4422	-1.6229	37.5000

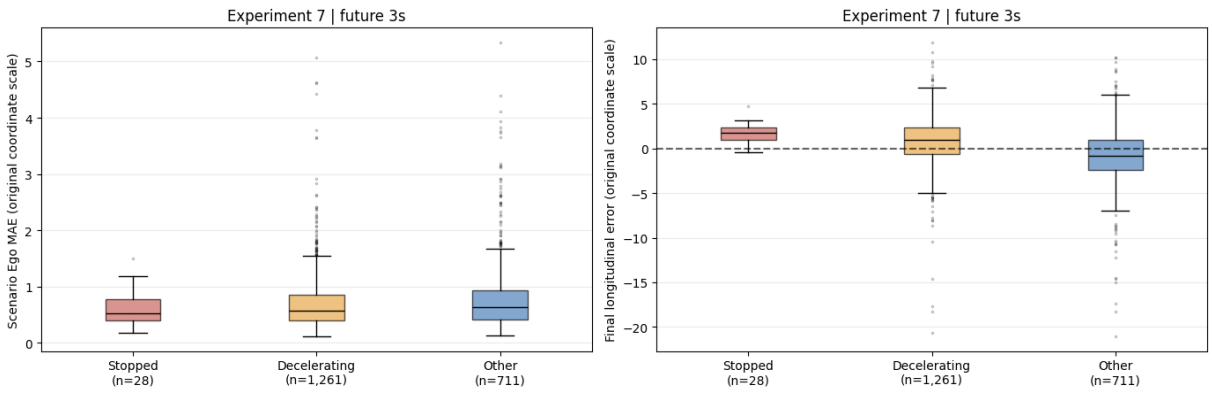


그림 9 정지·감속·기타 집단의 시나리오별 MAE 와 마지막 종방향 오차 분포 (1/2)

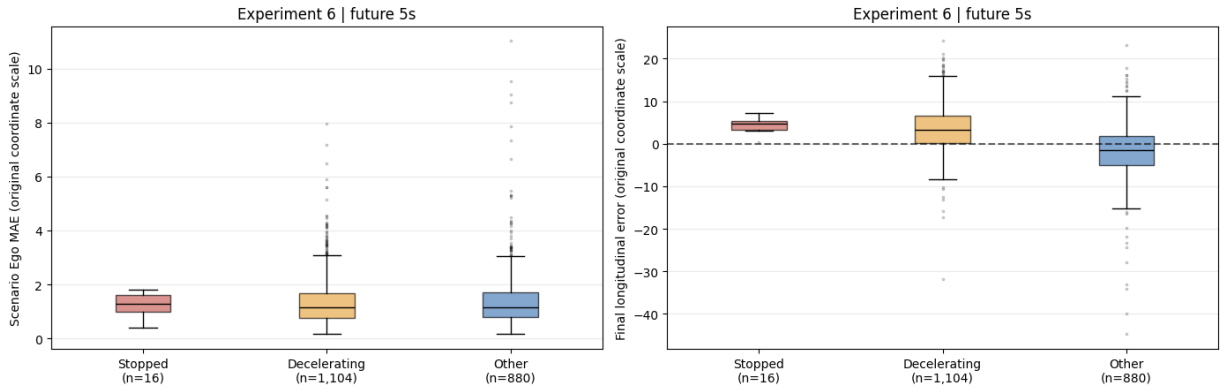


그림 9 정지·감속·기타 집단의 시나리오별 MAE 와 마지막 종방향 오차 분포 (2/2)

미래 3 초의 정지 사례 28 개에서 마지막 y 오차 평균은 +1.7370, 과대예측 비율은 92.86%였다. 미래 5 초의 정지 사례 16 개에서는 +4.4850 과 100%였다. 반면 정지 집단의 평균 MAE 가 가장 큰 것은 아니므로 전체 정확도 열세가 아니라 특정 상황의 방향 편향으로 해석한다. 서로 다른 모델과 집단의 3 초·5 초 차이를 예측 길이만의 효과로 설명하지 않는다.

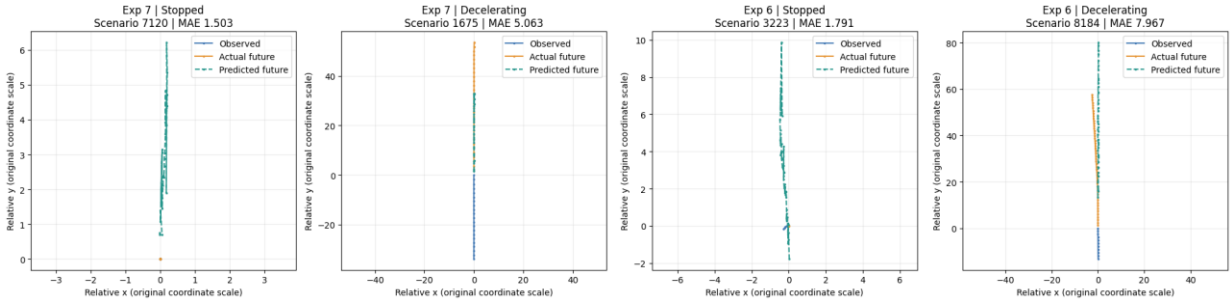


그림 10 각 정지·감속 집단에서 MAE 가 가장 큰 사례 대표 성능이 아닌 실패 사례

정지 집단의 좌표를 검산한 최대 이동거리는 원래 좌표 스케일 약 0.1535 였고, 모든 정지 사례의 마지막 종방향 변위가 0 임을 추가 확인했다. 작은 횡방향 변화의 원인은 단정하지 않는다. y 오차는 예측 y−실제 y 이며 양수라는 사실이 사고·충돌 위험을 뜻하지 않는다.

7. 좌표별 예측 오차 진단

예측 오차는 예측값−실제값으로 정의했다. LSTM 은 선형회귀의 선형성·등분산성 가정을 충족해야 학습 가능한 모형이 아니므로 본 분석은 가정의 합격 판정이 아니라 편향·오차 분포·시간 패턴의 진단이다. 반복 시점과 중첩 시나리오를 독립 표본으로 간주한 검정은 수행하지 않았다.

표 11 Ego 좌표별 오차 요약

실험	좌표	평균 편향	MAE	RMSE	절대오차 P90	절대오차 P99
7	x	0.0018	0.1058	0.1818	0.2592	0.7502
7	y	0.3410	1.3579	1.9840	3.0050	6.7553
6	x	0.0014	0.1628	0.2590	0.3938	0.9579
6	y	0.7497	2.5799	3.7066	5.6987	12.3364

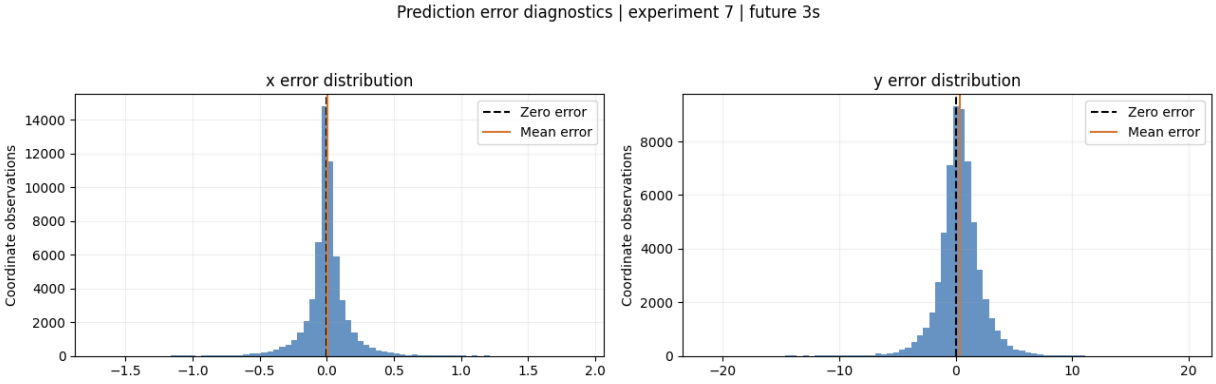


그림 11 실험 7 의 x·y 오차 분포와 예측값 대비 오차 산점도 (1/2)

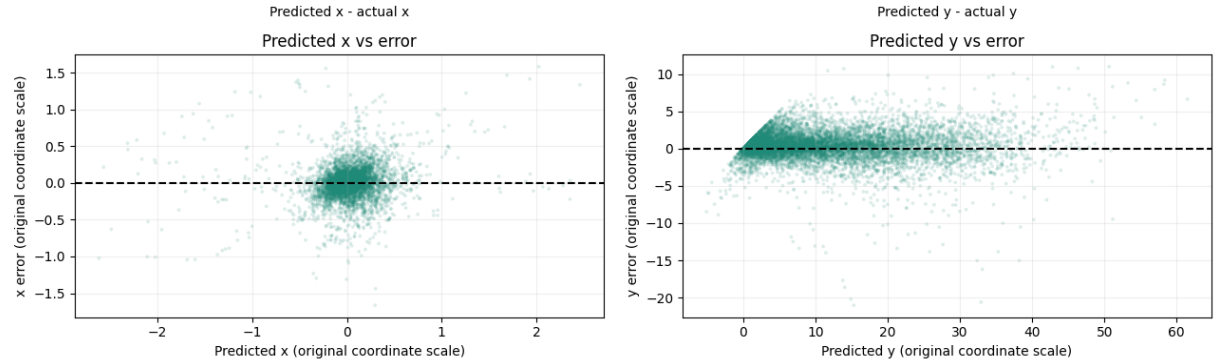


그림 11 실험 7 의 x·y 오차 분포와 예측값 대비 오차 산점도 (2/2)

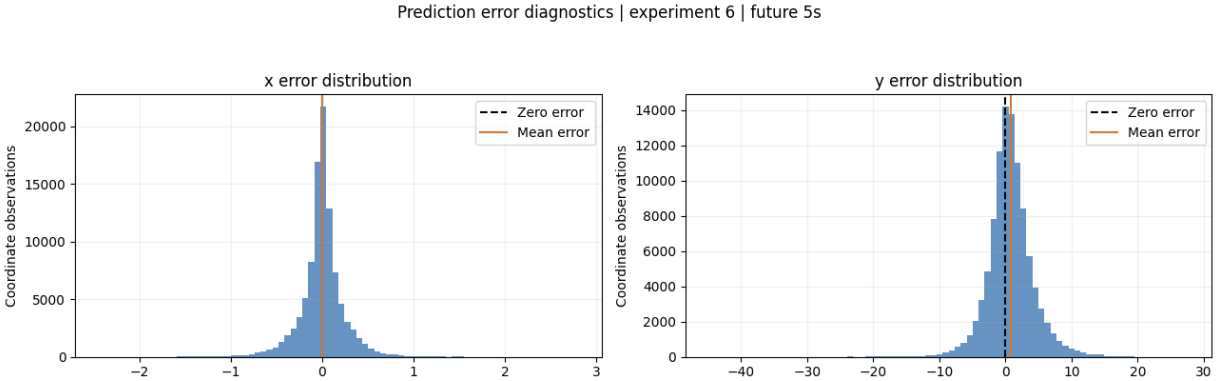


그림 12 실험 6 의 x·y 오차 분포와 예측값 대비 오차 산점도 (1/2)

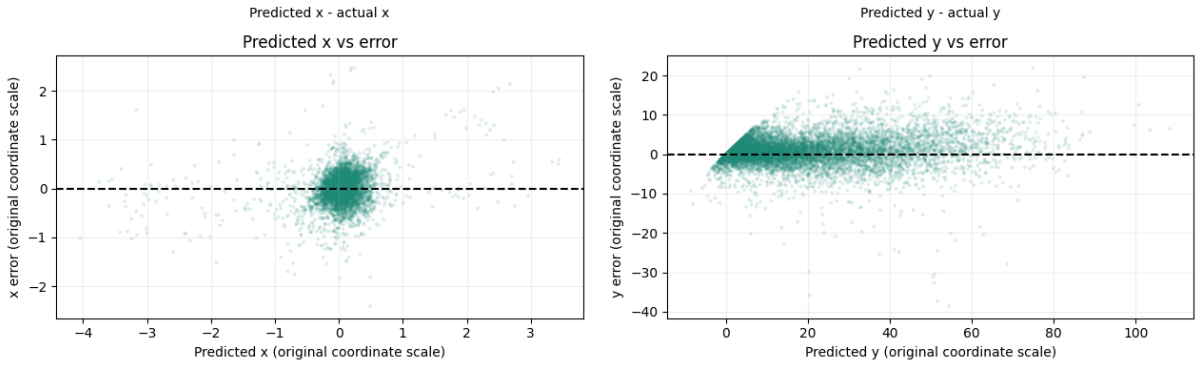


그림 12 실험 6 의 x·y 오차 분포와 예측값 대비 오차 산점도 (2/2)

횡방향 평균 편향은 0 에 가까웠으나 종방향 평균 편향은 3 초 +0.3410, 5 초 +0.7497 이었다. 종방향 오차 크기는 횡방향보다 컸지만 이동 범위 차이도 있어 학습 능력 차이로 단정하지 않는다. 중심부 집중과 꼬리가 함께 존재하며 예측값에 따른 퍼짐 변화도 보인다. 정규성·등분산성 검정으로 확인한 결과는 아니다. 산점도만 최대 10,000 점을 고정 난수로 추출했고 통계·히스토그램은 전체 값을 사용했다.

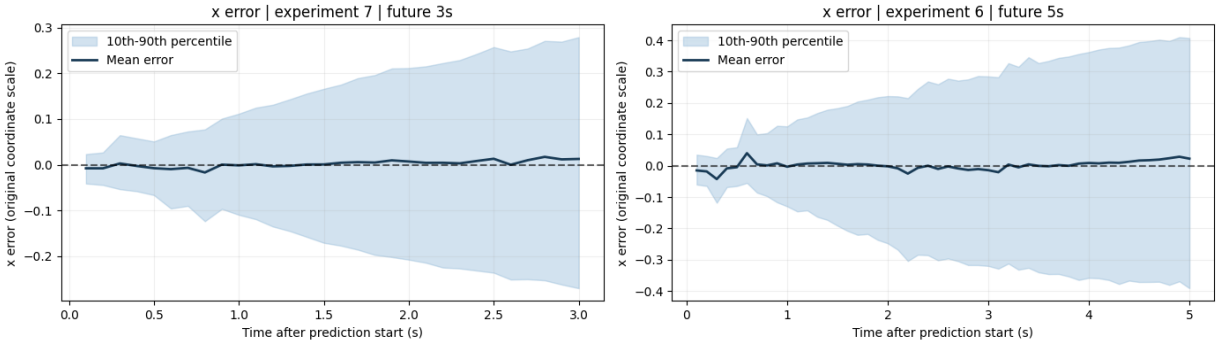


그림 13 예측 시간별 평균 오차와 경험적 10~90 백분위 범위 (1/2)

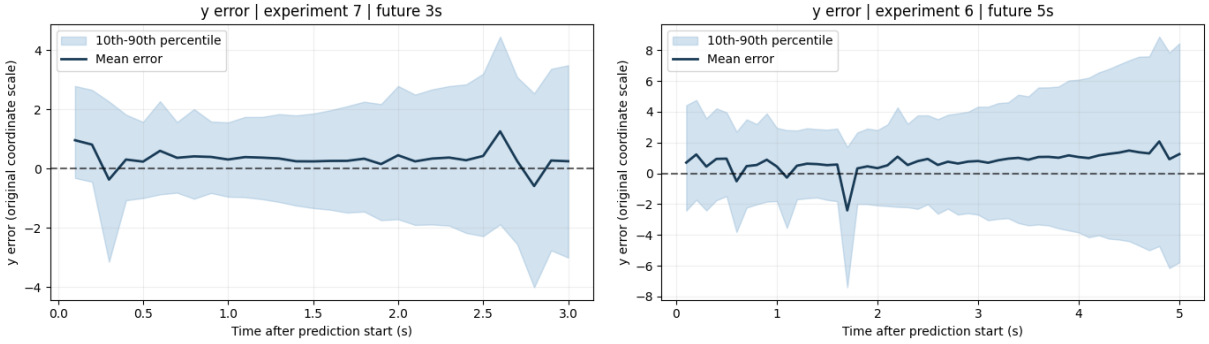


그림 13 예측 시간별 평균 오차와 경험적 10~90 백분위 범위 (2/2)

표 12 예측 마지막 시점의 오차 분포

실험	좌표	시간 초	평균 오차	P10	P90
7	x	3.0	0.0127	-0.2700	0.2789
7	y	3.0	0.2499	-3.0046	3.4923
6	x	5.0	0.0225	-0.3909	0.4072
6	y	5.0	1.2473	-5.7824	8.4375

예측 후반으로 갈수록 오차 범위가 확대돼 평균 편향만으로 개별 사례의 오차를 설명하기 어려웠다. 실험 6 의 5 초 마지막 y 오차 평균은 +1.2473, P10~P90 은 −5.7824~+8.4375 였다. 음영은 경험적 중앙 80% 범위이며 신뢰구간이나 보정된 예측구간이 아니다. 서로 다른 시나리오를 이어 자기상관을 계산하지 않았다.

8. 일정속도 기준 모델과 비교

복잡한 모델의 실용적 이점을 확인하기 위해 최근 1 초의 관측 좌표 변위를 1 초로 나누어 속도를 추정하고, 마지막 관측 위치에서 이 속도가 유지된다고 가정했다. 미래 정답과 속도 특성은 입력에 사용하지 않았다. LSTM 과 동일 평가 사례·Ego 좌표·기준 시점·미래 구간·원래 좌표 지표로 비교했다.

표 13 일정속도와 LSTM 비교

실험	미래 초	일정속도 MAE	LSTM MAE	일정속도 RMSE	LSTM RMSE	RMSE 감소 %
7	3	0.9343	0.7318	1.8712	1.4088	24.7151
6	5	1.8117	1.3713	3.7144	2.6274	29.2641

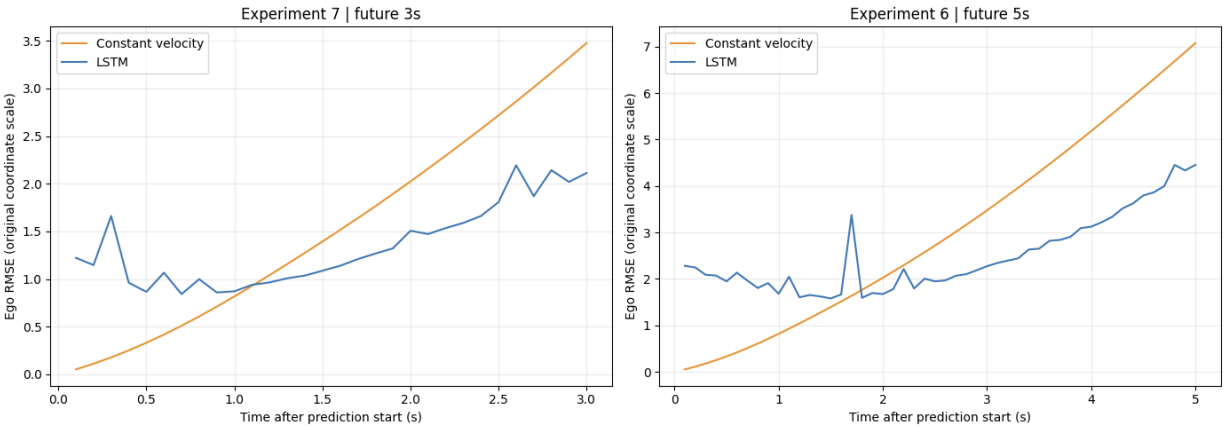


그림 14 일정속도 기준 모델과 선택 LSTM 의 미래 시점별 Ego RMSE

구간 전체 RMSE 감소율은 3 초 약 24.72%, 5 초 약 29.26%였다. 그러나 가까운 미래에서는 일정속도가 더 낮은 오차를 보이는 시점도 있었다. 따라서 모든 시점에서 우수하다고 주장하지 않는다. 최근 1 초 변위로 속도를 추정한 특정 기준 모델에 대한 결과이며 모든 기초 예측법보다 우수함을 뜻하지 않는다.

8.1 차량 단위 오차 차이의 불확실성

동일 평가 사례의 일정속도 MAE−LSTM MAE 를 계산하고, 같은 Ego 차량의 시나리오별 차이를 먼저 평균했다. 고유 차량 1,016 대에 같은 가중치를 부여하여 5,000 회 재표집했다. 이는 시나리오마다 같은 가중치를 주는 기존 비교와 추정 대상이 다르다. 3 초·5 초 두 비교에는 Bonferroni 방식으로 각각 명목 97.5% 양측 백분위 신뢰구간을 사용했다.

표 14 차량별 평균 MAE 차이의 탐색적 부트스트랩 결과

실험 / 미래	차량 수	일정속도 MAE	LSTM MAE	평균 차이	97.5% 구간
7 / 3 초	1,016	0.8974	0.7460	+0.1515	+0.1008 ~ +0.1988
6 / 5 초	1,016	1.7206	1.3969	+0.3237	+0.2353 ~ +0.4128

두 구간 모두 차이의 신뢰구간이 양수여서 현재 평가 자료의 차량별 평균 기준에서도 LSTM 에 유리한 방향이 관찰됐다. 이 분석은 결과를 본 뒤 추가한 사후 탐색이며 p 값을 산출한 사전 가설검정이 아니다. 고정 모델에 대한 재표집이므로 학습 난수의 변동은 포함하지 않는다. 차량 간 교통 상호작용과 학습·평가 중첩도 남아 있어 명목 신뢰수준의 정확한 보장이나 독립 장면에서의 통계적 우월성을 주장하지 않는다.

9. 분할 중첩과 결과의 한계

시나리오 인덱스, Ego 차량 ID, Ego 차량·프레임 조합, 주변 차량을 포함한 ID 를 집합 간 대조했다. Ego 조합은 각 시나리오 전체 71 개 시점에서 추출했다. 현재 분할과 모델을 변경하지 않고 평가 범위를 설명하기 위한 점검이다.

표 15 분할 집합 간 중첩

집합 A/B	동일 시나리오	공통 Ego	공통 Ego·프레임	A 중첩 %	B 중첩 %
학습/검증	0	704	51717	20.64	70.39
학습/평가	0	930	78581	31.37	70.64
검증/평가	0	540	27497	37.42	24.72

학습·평가의 동일 시나리오 인덱스 중복은 없지만 Ego 차량·프레임 조합 78,581 개가 겹쳤다. 평가 고유 조합의 70.64%다. 평가 시나리오 중 학습에 등장한 Ego 차량의 비율은 최신 저장 출력 기준 94.30%였다. 시나리오 번호만 다르게 나누어 독립 장면으로 분리한 평가라고 볼 수 없다.

결과는 현재 무작위 시나리오 분할 내 조건 비교로 제한한다. 미관측 차량·독립 장면·다른 도로에서의 일반화를 입증하려면 별도 분할과 재학습·평가가 필요하다. 단일 난수 학습, 차로 변화 평가 86 개, 정지 집단 28/16 개라는 표본 크기, 기본 지표의 부재 차량 채움값 포함도 함께 기록한다. 통계적 유의성이나 인과 효과는 주장하지 않는다.

10. 결론과 과제 연계

과제① 필수인 전체 시나리오 활용, 기본 LSTM 구성, 아키텍처 한 유형의 두 조건과 관측·예측 두 조건씩의 8 개 실험, MAE·RMSE 비교를 수행했다. 실제·예측 궤적 시각화와 EDA, 시간·상황별 오차, 정지·감속 실패 분석, 좌표별 진단, 일정속도 비교와 중첩 점검을 추가했다.

핵심 결과는 같은 시간 조건의 128 유닛이 낮은 정규화 오차를 보였다는 점, 관측 길이 증가의 이점이 일정하지 않았다는 점, 선택 모델이 특정 일정속도 기준보다 구간 전체 오차를 줄였지만 짧은 시점에는 항상 우수하지 않았다는 점이다. 직무 관점에서는 평균 KPI 뿐 아니라 상황별 방향 편향·꼬리 오차·자료 중첩을 함께 점검하는 모델 검증 과정으로 연결할 수 있다. 사고 위험이나 안전 효과를 검증한 결과는 아니다.

과제②에서는 5 조 배정 US-101 0805~0820, I-80 0500~0515 와 공통 CitySim RoundaboutA-01 을 별도로 처리하고 Convolutional Social Pooling LSTM 을 적용한다. 과제①과 데이터·평가 구성이 다르면 점수를 직접 비교해 모델 구조의 개선 효과라고 설명하지 않는다. 독립적인 비교 설계가 필요하다.

주요 비교 결과 요약

유닛 수 이번 고정 분할·단일 학습에서는 같은 시간 조건 네 쌍 모두 128 유닛의 정규화 MAE·RMSE 가 낮았다. 그러나 반복 학습이나 유의성 검정을 하지 않았으므로 안정적인 우열이 확정됐다고 표현하지 않는다.

과거 관측 길이 1 초에서 2 초로 늘렸을 때 일관된 개선은 없었다. 더 긴 관측이 항상 정확하다는 예상은 현재 결과에서 지지되지 않았다.

미래 예측 길이 대응되는 조건의 전체 7 대 원래 좌표 RMSE 는 5 초에서 더 높았다. 정규화 기준·평가 시점 구성도 달라지므로 차이를 예측 길이만의 독립적인 인과 효과나 거리 증가량으로 해석하지 않는다.

차로 상태 8 개 모델 모두 차로 ID 변화 집단의 Ego RMSE 가 유지 집단보다 높았다. 평가 사례는 유지 1,914 개·변화 86 개이며 주행 특성도 달라 차로 변화 자체의 인과 효과나 통계적 유의성을 주장하지 않는다.

기준 모델 선택한 3 초·5 초 모델의 구간 전체 Ego RMSE 는 해당 일정속도 기준보다 각각 약 24.72% · 29.26% 낮았다. 가까운 미래에서는 기준 모델이 더 낮은 시점도 있었으므로 모든 시점이나 모든 기초 방법에 우수하다는 뜻은 아니다. 차량별 평균 차이의 부트스트랩 구간도 두 모델 모두 양수였으나 사후 탐색적 보조 근거로 한정한다.

다섯 답변은 사후 탐색 결과의 요약이다. 학습·평가 자료의 차량·프레임 중첩을 고려하여 독립 장면 일반화 성능이나 가설의 입증으로 표현하지 않는다.

문헌 연결

Deo 와 Trivedi 의 연구는 주변 차량의 공간 관계와 운전 행동별 미래 가능성의 중요성을 보여준다. Zhang 등의 연구는 차량 상태 표현과 사회적 풀링 확장에 참고할 수 있다. CitySim 은 교통안전·디지털 트윈 활용 맥락에, Social GAN 은 보행자 대상이라는 차이를 명시한 상호작용·다중 미래 연구 흐름에 활용한다. 논문을 이유로 과제 필수 조건을 변경하거나 서로 다른 지표 점수를 직접 비교하지 않았다.

부록 재현 정보와 시각화 원본

정리본 노트북은 실행 준비 → 데이터 구조·품질 → EDA → 입력·분할·정규화 → 필수 실험·평가 → 추가 분석 → 기준 모델·중첩 → 결론 순서다. 기본값 RUN_TRAINING=False 는 기존 결과를 읽고, 필요한 추가 분석은 저장 모델로 추론한다. 원래 학습 코드는 재현을 위해 조건문 안에 보존했다.

실험 폴더: PBL1_results/course_required_20261109_062604_119669. 필수 파일은 manifest.json, split_indices.npz, validation_results.csv, validation_selected_models.csv, test_results.csv 와 각 experiment_01~08 의 config.json, scalers.joblib, best_model.keras, training_log.csv 다.
모델·scaler·분할은 같은 폴더의 파일을 함께 사용한다.

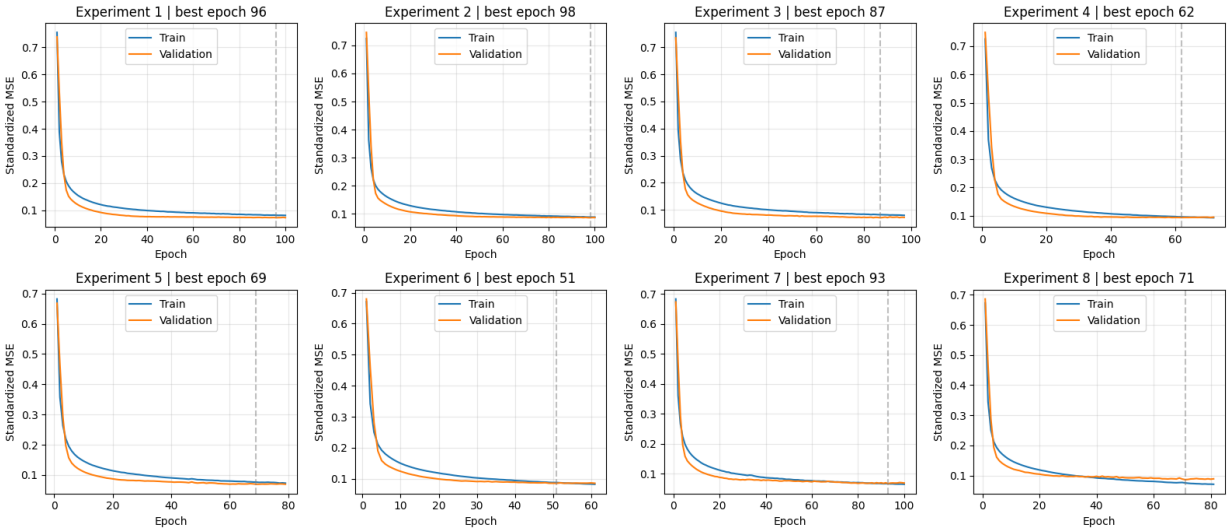


그림 15 노트북에 저장된 8 개 학습 곡선 원본 본문에서는 두 묶음으로 확대 배치

참고문헌

[1] Deo, N., & Trivedi, M. M. (2018). Convolutional Social Pooling for Vehicle Trajectory Prediction. CVPR Workshops. https://arxiv.org/abs/1805.06771

[2] Deo, N., & Trivedi, M. M. (2018). Multi-Modal Trajectory Prediction of Surrounding Vehicles with Maneuver based LSTMs. IEEE IV. https://arxiv.org/abs/1805.05499

[3] Zhang, H., et al. (2020). A Multi-Modal States based Vehicle Descriptor and Dilated Convolutional Social Pooling for Vehicle Trajectory Prediction. https://arxiv.org/abs/2003.03480

[4] Zheng, O., et al. (2023). CitySim: A Drone-Based Vehicle Trajectory Dataset for Safety-Oriented Research and Digital Twins. Transportation Research Record. https://doi.org/10.1177/03611981231185768

[5] Gupta, A., et al. (2018). Social GAN: Socially Acceptable Trajectories with Generative Adversarial Networks. CVPR. https://arxiv.org/abs/1803.10892